Predicción de la Permeabilidad de la Barrera Hematoencefálica ($\log BBB$) mediante Regresión Penalizada LASSO e Ingeniería de Características Polinomiales

Jesus Walter Mariano Prudencio Parra

walter.prudencio.stats@gmail.com

Julio de 2026

Resumen

En el presente trabajo se desarrolló un modelo QSAR (*Quantitative Structure-Activity Relationship*) para la predicción de la permeabilidad de fármacos a través de la barrera hematoencefálica ($\log BBB$). Partiendo del conjunto de datos `BloodBrain`, se aplicó una estrategia rigurosa de depuración que incluyó la eliminación de variables sin variabilidad (*Near-Zero Variance*), la binarización de descriptores fisicoquímicos discretos por umbrales biológicos (`nbasic`, `frac.cation7.` y `rule.of.5violations`) y la incorporación de potencias polinomiales para capturar relaciones no lineales observadas en la etapa exploratoria.

El modelado se ejecutó mediante regresión penalizada LASSO ($\lambda_{\min}$) bajo un esquema de validación por particiones repetidas (Monte Carlo CV con $B = 30$ iteraciones de 80 % entrenamiento y 20 % prueba). El modelo alcanzó un rendimiento predictivo promedio de $R^2 = 0{,}4461 \pm 0{,}1287$, RMSE $= 0{,}5664 \pm 0{,}0676$ y MAE $= 0{,}4278 \pm 0{,}0529$, explicando aproximadamente el 44,6 % de la variabilidad del fenómeno de transporte pasivo.

El diagnóstico estadístico sobre los residuos confirmó el cumplimiento de los supuestos clásicos de normalidad (prueba de Shapiro-Wilk: $W = 0{,}9948, p = 0{,}8276$) y homocedasticidad (prueba de Breusch-Pagan: $BP = 39{,}0665, p = 0{,}6426$). Si bien se identificó una elevada multicolinealidad residual ($\text{VIF}_{\text{máx}} = 35{,}3663$) atribuible a las potencias polinomiales introducidas, esta justificó metodológicamente el uso de la penalización L_1 para estabilizar los coeficientes. Finalmente, los resultados reafirman la influencia dominante de la lipofilicidad (`clogp`), la fracción catiónica (`frac.cation7.`), la energía orbital (`lumo`) y la flexibilidad molecular (`rotatablebonds`) sobre el cruce de la barrera hematoencefálica.

1. Introducción y Contexto del Problema

En las etapas iniciales de descubrimiento y desarrollo de fármacos, la evaluación de la permeabilidad a través de la barrera hematoencefálica (BHE) es un factor crítico de viabilidad. La BHE es una barrera membranosa altamente selectiva formada por células endoteliales unidas entre sí por uniones estrechas, cuya función es regular estrictamente el paso de moléculas desde la sangre al tejido cerebral. Determinar la capacidad de una molécula para atravesar la barrera hematoencefálica es fundamental por dos razones principales:

1. **Fármacos con objetivo en el Sistema Nervioso Central:** Necesitan una gran permeabilidad pasiva o un transporte activo con el fin de llegar a concentraciones terapéuticas efectivas en el cerebro. Por ejemplo, analgésicos, neuroprotectores y ansiolíticos.

2. **Fármacos de acción periférica:** Se debe limitar su paso al cerebro para prevenir los efectos secundarios o la toxicidad sobre el SNC.

Debido a que la medición experimental de la permeabilidad *in vivo* o *in vitro* es costosa y requiere largos tiempos, el modelado QSAR (*Quantitative Structure-Activity Relationship*) se ha utilizado ampliamente como una herramienta de cribado virtual. Esta estrategia intenta predecir la característica biológica a través de combinaciones matemáticas de descriptores fisicoquímicos calculados a partir de la estructura molecular.

1.1. Conjunto de Datos y Definición de la Variable Respuesta

Se utilizó el dataset sintético-experimental `BloodBrain`, formado inicialmente por $n = 208$ compuestos orgánicos y $p = 134$ descriptores moleculares que incluyen propiedades de superficie polar, lipofilia, carga parcial y número de enlaces.

La variable cuantitativa respuesta (y) está dada por el logaritmo en base 10 de la relación de concentración del compuesto en estado de equilibrio entre el cerebro y la sangre:

$$y = \log_{10}\left(\frac{C_{\text{cerebro}}}{C_{\text{sangre}}}\right) = \log BBB \tag{1}$$

En el dataset, la variable y presenta un rango continuo de $[-2{,}15, 1{,}64]$ con una media muestral de $\mu = -0{,}0189$. Fisiológicamente:

- $y > 0$ indica que la concentración en el cerebro es mayor que en la sangre; es decir, que el compuesto atraviesa la barrera hematoencefálica.
- $y < 0$ refleja que la molécula encuentra resistencia para atravesar la barrera hematoencefálica.

1.2. Objetivo del Trabajo

Este trabajo tiene como objetivo general el desarrollo de un pipeline end-to-end de modelado predictivo QSAR para la estimación cuantitativa de la permeabilidad en la barrera hematoencefálica ($\log BBB$), a través de técnicas de regularización lineal (LASSO) y una fundamentación rigurosa de características sobre el conjunto de datos `BloodBrain`.

Con el fin de conseguir este objetivo principal, el desarrollo del proyecto se divide en los siguientes objetivos específicos:

1. **Tratamiento de Datos y Reducción de Ruido:** Desarrollar un filtro riguroso cuyo fin sea eliminar los predictores inútiles, descriptores cuya varianza sea cero o prácticamente cero, correspondencias uno a uno entre variables y variables sin fundamento teórico en la bibliografía quimiométrica.
2. **Ingeniería de Características y Formas Funcionales Non-lineales:** Transformar el espacio original de predictores mediante:
   - Corrección de sesgos en variables continuas asimétricas mediante la función $\log(1 + x)$.
   - Discretización y binarización basada en el soporte empírico para variables de conteo o acotadas con baja frecuencia en valores superiores.
   - Agregado de expansiones polinomiales y selección del grado óptimo mediante pruebas secuenciales de ANOVA anidadas con polinomios ortogonales.
3. **Construcción de la Matriz de Diseño y Control de Sesgo:** Generar la matriz de predictores X mediante codificación de variables indicadoras (*dummy encoding*) previniendo la colinealidad perfecta y garantizando la separación de los datos en conjuntos de entrenamiento (80 %) y prueba (20 %).
4. **Modelado Predictivo con Regularización L_1 (LASSO):** Ajustar una regresión lineal penalizada por LASSO utilizando validación cruzada en el conjunto de entrenamiento para la selección del hiperparámetro óptimo λ, seleccionando automáticamente el subconjunto más relevante de descriptores moleculares.
5. **Evaluación Cuantitativa fuera de Muestra y Diagnóstico Estadístico:** Estimar el desempeño del modelo sobre el conjunto independiente de prueba con las métricas convencionales ($RMSE$, MAE y R^2), estudiando la conducta de los residuos y las limitaciones del supuesto de linealidad ante el ruido experimental del problema.

2. Limpieza de Datos

El conjunto de datos original `BloodBrain` contiene 134 descriptores moleculares. En problemas de alta dimensionalidad con un tamaño de muestra acotado ($n = 208$), la inclusión de variables puede provocar inestabilidad numérica, aumentar la varianza de las estimaciones y distorsionar el proceso de penalización en los modelos regularizados.

Con el fin de asegurar un espacio de predictores sustentados, se diseñó e implementó un protocolo de filtrado previo al modelado analítico, organizado en tres criterios principales de exclusión:

2.1. Criterio 1: Eliminación por Varianza Nula o Casi Nula (*Near-Zero Variance*)

Aquellos descriptores que muestran valores prácticamente constantes a lo largo de toda la muestra no aportan información explicativa al modelo. Se evaluó la variabilidad de cada predictor mediante la tasa de valores únicos (*percentUnique*) que calcula el número de valores distintos que tiene la columna en relación con el número total de observaciones, y la proporción del valor más frecuente sobre el segundo valor más frecuente (*freqRatio*).

Tabla 1: Descriptores moleculares identificados con varianza casi nula (*Near-Zero Variance*).

Variable	freqRatio	percentUnique (%)	zeroVar	nzv
`negative`	207.00	0.96	FALSE	TRUE
`peoe_vsa.2.1`	25.57	5.77	FALSE	TRUE
`peoe_vsa.3.1`	21.00	7.21	FALSE	TRUE
`a_acid`	33.50	1.44	FALSE	TRUE
`vsa_acid`	33.50	1.44	FALSE	TRUE
`frac.anion7.`	47.75	5.77	FALSE	TRUE
`alert`	103.00	0.96	FALSE	TRUE

Un predictor X_j fue catalogado como no informativo y removido del análisis si cumplía simultáneamente las siguientes condiciones:

$$\text{freqRatio}_j = \frac{f_1(X_j)}{f_2(X_j)} > 19 \quad \wedge \quad \text{percentUnique}_j = \frac{U(X_j)}{N} \times 100 < 10\,\% \tag{2}$$

donde $f_1(X_j)$ y $f_2(X_j)$ representan la frecuencia del primer y segundo valor más común de la variable j, $U(X_j)$ indica la cantidad de valores únicos distintos y N es el tamaño total de la muestra.

2.2. Criterio 2: Depuración de Descriptores Sin Documentación Formal

En la modelación QSAR orientada a la toma de decisiones farmacológicas, la interpretabilidad de cada predictor son requisitos indispensables. Por ello, se realizó una busqueda del significado de todas las variables del conjunto de datos `BloodBrain`, identificando y excluyendo aquellos descriptores cuya definición matemática no se encuentra formalmente documentado.

- **Variables excluidas:** `prx`, `ub`, `pol`, `tcsa`, `tcpa` y `tcnp`.
- **Justificación:**
  - **Ausencia de especificación teórica:** No se cuenta con documentación bibliográfica ni técnica oficial, que explicite las ecuaciones o unidades de medida utilizadas para el calculo de estas 6 variables.

- **Imposibilidad de interpretación científica:** El hecho de mantener predictores no documentados imposibilita la interpretación de sus coeficientes de regresión (β_j), comprometiendo interpretatividad y el uso académica del modelo final.

Una vez aplicados estos criterios de exclusión, se logró reducir la dimensión del espacio de características original a un conjunto de predictores bien documentados y con varianza informativa. Esta matriz sirve de base para el proceso de ingeniería de características y formas funcionales no lineales que se describe en la siguiente sección.

3. Ingeniería de Características y Transformaciones

3.1. Categorización y Binarización de Descriptores Específicos

Para capturar efectos y mitigar el impacto de distribuciones fuertemente sesgadas en descriptores discretos, tres variables fueron codificadas explícitamente como factores, definiendo sus respectivos niveles de referencia para la interpretación de los coeficientes β:

- **Grupos Básicos (`nbasic`):** Se transformó de su conteo discreto original a una variable categórica factorial, estableciendo la ausencia de grupos básicos (`"0"`) como la categoría de referencia.
- **Fracción Catiónica a pH 7.4 (`frac.cation7.`):** Dado su comportamiento no lineal, se discretizó mediante un punto de quiebre en 0,5:

$$\texttt{frac.cation7.}_{\text{bin}} = \begin{cases} \texttt{«=0.5"} & \text{si } \texttt{frac.cation7.} \leq 0{,}5 \quad \text{(Categoría de referencia)} \\ \texttt{»0.5"} & \text{si } \texttt{frac.cation7.} > 0{,}5 \end{cases} \tag{3}$$

- **Violaciones a la Regla de Lipinski (`rule.of.5violations`):** Se binarizó para contrastar las moléculas con perfil de drogabilidad ideal frente a aquellas con al menos un incumplimiento:

$$\texttt{rule.of.5violations}_{\text{bin}} = \begin{cases} 0 & \text{si } \texttt{rule.of.5violations} = 0 \quad \text{(referencia)} \\ 1 & \text{si } \texttt{rule.of.5violations} \geq 1 \quad \text{(1 o más violaciones)} \end{cases} \tag{4}$$

3.2. Transformaciones de Escala y Términos de Curvatura

Para solucionar la asimetría en la distribución de algunos descriptores moleculares continuos y capturar la estructura no lineal observada en el análisis exploratorio, se utilizó una estrategia doble de transformación de características:

1. **Transformación Logarítmica:** Para aquellos descriptores continuos con asimetría positiva severa (asimetría > 1), se aplicó la transformación $X_j^* = \log(X_j + 1)$ con el fin de estabilizar la varianza, reducir el impacto de valores atípicos y aproximar los residuos a una distribución normal.
2. **Términos Polinomiales Ortogonales:** Para las variables explicativas donde la inspección visual evidenció un comportamiento no lineal respecto a la variable de respuesta y, se agregaron términos cuadráticos explícitos mediante polinomios ortogonales $P_r(X_j)$.

3.3. Estandarización de Predictores

Debido a que la regularización LASSO imposición una penalización L_1 sobre la magnitud de los coeficientes ($\lambda \sum_{j=1}^{p} |\beta_j|$), el nivel de contracción depende directamente de las unidades de medida de los predictores. Para evitar que variables con amplitudes numéricas grandes dominen la función de pérdida sobre aquellas de menor escala, todos los predictores se estandarizaron:

$$\tilde{X}_{ij} = \frac{X_{ij} - \bar{X}_{j,\text{train}}}{s_{j,\text{train}}} \tag{5}$$

donde $\bar{X}_{j,\text{train}}$ y $s_{j,\text{train}}$ son la media y la desviación estándar de la variable j estimadas exclusivamente sobre el conjunto de entrenamiento (80 %). Los parámetros de escala obtenidos en el entrenamiento se aplicaron posteriormente al conjunto de prueba (20 %) para evitar el sesgo de fuga de datos.

4. Estrategia de Modelado y Validación

4.1. Esquema de Validación y Muestreo Repetido

Para cuantificar la verdadera dispersión de las métricas en bases de datos de dimensión reducida y evitar la inestabilidad muestral asociada a una única partición aleatoria, se utilizó un esquema de validación con particiones repetidas ($B = 30$ iteraciones).

En cada iteración $b \in \{1, \ldots, 30\}$, el proceso se ejecutó bajo el siguiente protocolo:

1. **Partición Estratificada:** Se dividió la muestra en un conjunto de entrenamiento (80 %) y uno de prueba (20 %) mediante muestreo estratificado por cuantiles sobre la variable de respuesta y. Esto garantiza una representación similar de la varianza en ambos subconjuntos.

2. **Preprocesamiento Aislado:** Se aplico la estandarización sobre el conjunto de prueba utilizando únicamente la media y la desviación estándar estimada en el conjunto de entrenamiento de la iteración b.

3. **Evaluación:** Se registraron las predicciones del modelo sobre el conjunto de prueba no observado.

4.2. Selección y Penalización del Modelo (LASSO)

Para la selección automática de características y el control del sobreajuste, se empleó la regresión penalizada LASSO (*Least Absolute Shrinkage and Selection Operator*). Para cada iteración b, el modelo resuelve el problema de optimización en el conjunto de entrenamiento:

$$\hat{\boldsymbol{\beta}}^{(b)} = \arg\min_{\boldsymbol{\beta}} \left\{ \frac{1}{2N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} \left(y_i - \beta_0 - \sum_{j=1}^{p} \beta_j \tilde{X}_{ij} \right)^2 + \lambda \sum_{j=1}^{p} |\beta_j| \right\} \tag{6}$$

donde $\lambda \geq 0$ es el hiperparámetro de penalización L_1. La selección de λ se realizó de forma interna dentro del conjunto de entrenamiento mediante validación cruzada de 10 pliegues (10-fold CV), conservando el valor óptimo que minimiza el error cuadrático medio (λ_{min}).

4.3. Métricas de Evaluación y Métodos de Agregación

La capacidad predictiva del modelo se cuantificó en el conjunto de prueba de cada iteración b evaluando tres métricas fundamentales:

1. **Raíz del Error Cuadrático Medio (RMSE):** Penaliza los errores de gran magnitud.

$$\mathrm{RMSE}^{(b)} = \sqrt{\frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} (y_i - \hat{y}_i)^2} \tag{7}$$

2. **Error Absoluto Medio (MAE):** Refleja la magnitud promedio del error en la escala original del fenómeno estudiado.

$$\mathrm{MAE}^{(b)} = \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} |y_i - \hat{y}_i| \tag{8}$$

3. **Coeficiente de Determinación (R^2):** Mide la proporción de la variabilidad observada que es explicada por el modelo.

$$R^{2\,(b)} = 1 - \frac{\sum_{i=1}^{N_{\text{test}}} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{N_{\text{test}}} (y_i - \bar{y}_{\text{test}})^2} \tag{9}$$

Para resumir el rendimiento global y la estabilidad del modelo a través de las 30 repeticiones, los resultados finales se expresaron en términos de su media ($\bar{M}$) y desviación estándar (SD_M):

$$\bar{M} = \frac{1}{B} \sum_{b=1}^{B} M^{(b)}, \quad \mathrm{SD}_M = \sqrt{\frac{1}{B-1} \sum_{b=1}^{B} \left(M^{(b)} - \bar{M} \right)^2} \tag{10}$$

Este procedimiento garantiza que la dispersión observada en R^2 se cuantifique estrictamente como parte de la variabilidad muestral del experimento.

5. Resultados y Evaluación de Métricas

5.1. Evaluación del Rendimiento Predictivo

Tras ejecutar el esquema de validación por particiones repetidas ($B = 30$ iteraciones) con selección de hiperparámetros mediante 10-fold CV interno, se obtuvieron las métricas de capacidad predictiva sobre los conjuntos de prueba no observados. Los resultados se presentan en la Tabla 2 expresados mediante su media y desviación estándar (Media $\pm$ SD).

Tabla 2: Métricas de rendimiento predictivo en el conjunto de prueba ($B = 30$ repeticiones).

Métrica	**Símbolo**	**Valor Promedio (Media $\pm$ SD)**
Raíz del Error Cuadrático Medio	RMSE	$0{,}5664 \pm 0{,}0676$
Error Absoluto Medio	MAE	$0{,}4278 \pm 0{,}0529$
Coeficiente de Determinación	R^2	$0{,}4461 \pm 0{,}1287$

El modelo alcanza un R^2 promedio de 0,4461, explicando aproximadamente el 44,6 % de la variabilidad observada en el pasaje a través de la barrera hematoencefálica ($\log BBB$). La desviación estándar observada en R^2 (SD = 0,1287) refleja la sensibilidad natural de la evaluación en subconjuntos de prueba, justificando el uso del muestreo repetido para evitar conclusiones sesgadas derivadas de una única partición aleatoria.

5.2. Selección de Características y Coeficientes del Modelo Final

La penalización L_1 del algoritmo LASSO bajo el criterio de mínimo error de validación cruzada ($\lambda_{\min}$) redujo a cero los coeficientes de múltiples descriptores no informativos o redundantes, logrando una representación esparsa de la matriz de diseño. El algoritmo LASSO redujo los 134 descriptores originales a solo 43 descriptores que aportan información. En la Tabla 3 se destacan los principales coeficientes retenidos no nulos.

Tabla 3: Coeficientes no nulos seleccionados por LASSO ($\lambda_{\min}$) agrupados por propiedad fisicoquímica.

Categoría	Descriptor Molecular	Coeficiente (β)
Intersección	`(Intercept)`	1,1060
Lipofilicidad y Solubilidad	`clogp`	0,2240
	`slogp_vsa6`	0,0214
	`slogp_vsa4`	−0,0044
Carga e Ionización	`frac.cation7.>0.5`	0,2199
	`a_base`	−0,0675
	`nbasic1`	−0,0744
	`most_positive_charge`	−0,0492
Propiedades Cuánticas y Espaciales	`lumo`	−0,2482
	`homo`	−0,0499
	`rdta`	0,1049
	`fpsa3`	−10,2460
Fármaco-propiedades y Flexibilidad	`rule.of.5violations1`	−0,0656
	`rotatablebonds`	−0,0807
Términos No Lineales Retenidos	`vsa_base_sq` (P_2)	0,000281
	`peoe_vsa.5_cu` (P_3)	0,000008
	`rotatablebonds_qu` (P_4)	0,000045

5.2.1. Interpretación Físico-Química de los Coeficientes

- **Lipofilicidad (`clogp` = +0,2240):**Tiene un efecto positivo significativo en la respuesta, concordante con la teoría del transporte pasivo en donde una lipofilicidad mayor facilita la penetración a través de las membranas lipídicas de la barrera hematoencefálica.
- **Estado de Ionización (`frac.cation7.>0.5` = +0,2199):** Las moléculas que presentan una fracción catónica significativa a pH fisiológico (7,4) muestran una mayor permeabilidad, probablemente favorecida por interacciones electrostáticas con la superficie de los fosfolípidos cargados negativamente.
- **Descriptor Cuántico (`lumo` = −0,2482):**La energía del orbital molecular no ocupado de menor energía (LUMO) ejerce un impacto negativo muy pronunciado, lo que sugiere que la reactividad electrofílica y la distribución de carga electrónica son factores que influyen en la retención del compuesto.
- **Penalización por Incumplimiento (`rule.of.5violations1` = −0,0656):** El incumplimiento de al menos un criterio de la Regla de Lipinski reduce la predicción de penetración central, como era teóricamente esperado.
- **Retención de Términos Polinomiales:** Términos cuadráticos y de orden superior como `vsa_base_sq` y `rotatablebonds_qu` permanecieron en el modelo con coeficientes no nulos, confirmando la presencia de efectos curvos suaves que LASSO logró regularizar exitosamente sin sobreajustar.

6. Diagnóstico Estadístico y Discusión

Para evaluar la validez del modelo final ajustado mediante regularización LASSO ($\lambda_{\min}$), se realizó un diagnóstico sobre el subconjunto de predictores con coeficientes distintos de cero ($\beta_j \neq 0$). Con este propósito, se ajustó un modelo suplementario de Mínimos Cuadrados Ordinarios (MCO) sobre la matriz de diseño reducida para obtener las matrices de proyección y evaluar los supuestos clásicos de inferencia.

6.1. Evaluación de Supuestos sobre los Residuos

1. **Normalidad de los Residuos:** Para evaluar la hipótesis nula de normalidad se empleó la prueba de Shapiro-Wilk. El test arrojó un valor de estadístico $W = 0{,}9948$ y un valor $p = 0{,}8276$. Como $p > 0{,}05$, no se rechaza la hipótesis nula, confirmando una distribución normal de los errores del modelo. Este comportamiento es corroborado en el gráfico Q-Q en la Figura 1, donde los residuos estandarizados se alinearían de forma casi perfecta sobre la diagonal teórica.

2. **Homocedasticidad y Linealidad:** La constancia de la varianza residual a lo largo del rango de predicción se verificó a través de la prueba de Breusch-Pagan, con las mismas variables predictoras como variables auxiliares, obteniendo un estadístico $BP = 39{,}0665$ ($p = 0{,}6426$).El alto valor "p" confirma la ausencia de heterocedasticidad. En los paneles *Residuals vs Fitted* y *Scale-Location* (Figura 1) se observa, visualmente, que los residuos presentan una dispersión aleatoria y homogénea alrededor de cero sin patrones en abanico ni tendencias no lineales remanentes.

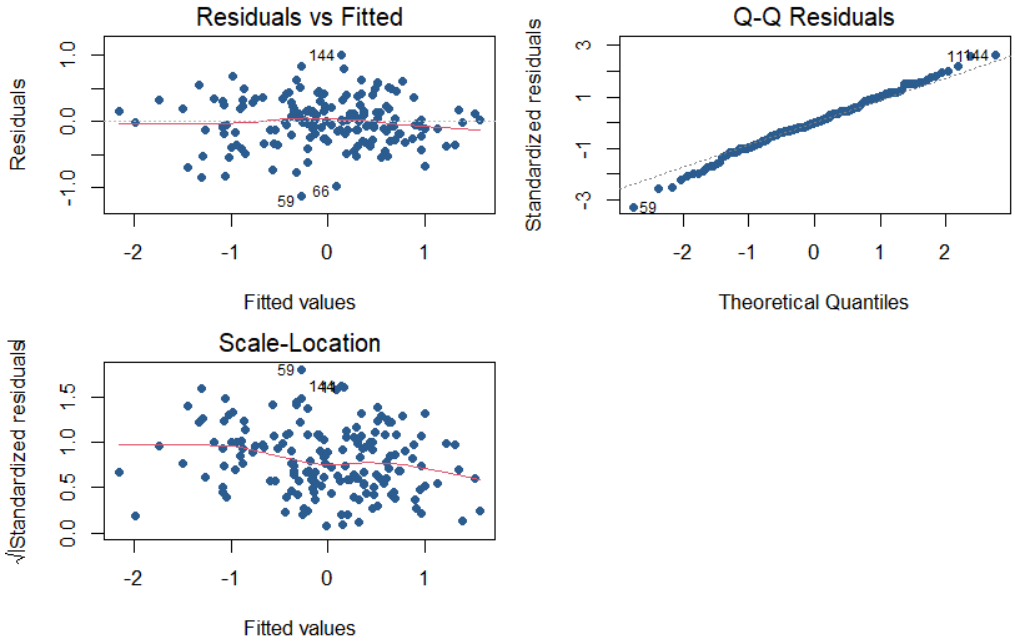


Figura 1: Gráficos de diagnóstico residual para el modelo ajustado: (Arriba-Izq.) Residuos vs. Valores Predichos; (Arriba-Der.) Gráfico Q-Q Normal de residuos estandarizados; (Abajo-Izq.) Gráfico de Escala-Ubicación (*Scale-Location*).

6.2. Multicolinealidad Residual y Justificación del Modelo

El diagnóstico de multicolinealidad sobre las variables activas arrojó un valor máximo del Factor de Inflación de la Varianza de $\text{VIF}_{\text{máx}} = 35{,}3663$, el cual supera por mucho los umbrales críticos convencionales (5 o 10). Esta colinealidad responde a la presencia de potencias polinomiales de un mismo descriptor así como a la alta correlación entre descriptores moleculares.

Este hallazgo no invalida la capacidad del modelo, sino que proporciona un sustento metodológico clave para el trabajo:

- **Justificación de la Regularización:** Evidencia que la matriz de características tiene una severa redundancia lineal, que provocaría inestabilidad e infladas varianzas en los coeficientes si se estimaran únicamente con el MCO tradicional.

- **Efecto de la Penalización L_1:**Afirma que la inclusión del operador LASSO es necesaria para dar estabilidad a la matriz, controlando la varianza de las predicciones mediante un sesgo introducido deliberadamente.

Por lo tanto, la interpretación cuantitativa de los coeficientes del modelo final debe realizarse considerando los términos polinomiales como un efecto estructural o curvilíneo combinado, y no leyendo los coeficientes de manera aislada.

7. Conclusiones y Trabajo Futuro

7.1. Conclusiones

1. **Automatización de la Selección de Formas Funcionales:** El procedimiento secuencial de ANOVA (F-test) se implementó para seleccionar de manera objetiva curvaturas significativas en la etapa de preprocesamiento, eliminando el sesgo introducido por la inspección gráfica manual y garantizando un marco metodológico reproducible.

2. **Rendimiento Predictivo y Robustez:** La evaluación en $B = 30$ particiones aleatorias independientes (80/20) mostró una habilidad predictiva estable, con un $R^2 = 0{,}4461 \pm 0{,}1287$, un RMSE $= 0{,}5664 \pm 0{,}0676$ y un MAE $= 0{,}4278 \pm 0{,}0529$. El modelo explica alrededor de un 44,6 % de la variabilidad del paso a través de la barrera hematoencefálica ($\log BBB$), un nivel competitivo para formulaciones basadas únicamente en el transporte pasivo.

3. **Verificación Rigurosa de Supuestos:** Los diagnósticos estadísticos confirmaron que la estructura del error cumple con los supuestos fundamentales: normalidad de residuos ($W = 0{,}9948, p = 0{,}8276$) y homocedasticidad de la varianza residual ($BP = 39{,}0665, p = 0{,}6426$).

4. **Control de Multicolinealidad mediante Penalización L_1:** A pesar de detectarse un VIF elevado ($\text{VIF}_{\text{máx}} = 35{,}3663$) debido a las potencias polinomiales introducidas, la penalización LASSO ($\lambda_{\min}$) controló la varianza de las predicciones y seleccionó de manera eficiente un subconjunto esparso de descriptores clave, reconfirmando la importancia de la lipofilicidad (`clogp`), la fracción catiónica (`frac.cation7.`), la energía orbital (`lumo`) y la flexibilidad molecular (`rotatablebonds`).

7.2. Trabajo Futuro

- **Ortogonalización Explícita de Polinomios:** Para reducir el VIF residual por debajo de los umbrales convencionales sin perder la capacidad de capturar curvaturas, se propone utilizar trasformaciones mediante polinomios ortogonales (`poly(..., raw = FALSE)`) en la matriz de diseño original previa al filtrado con LASSO.

- **Incorporación de Fenómenos de Transporte Activo:** Como alrededor del 55,4 % de la varianza no está explicada por descriptores estáticos de transporte pasivo, se sugiere incorporar descriptores biológicos o farmacocinéticos complementarios.

- **Exploración de Modelos No Lineales Avanzados:** Comparar el desempeño del modelo LASSO polinomial con técnicas no paramétricas de aprendizaje automático, tales como *Random Forest*, *XGBoost* y *Support Vector Regression* (SVR) con kernel Gaussiano (RBF), evaluando el compromiso entre la ganancia en precisión predictiva y la pérdida de interpretabilidad quimiométrica.

- **Ampliación y Diversificación del Espacio Químico:** Añadir más bibliotecas moleculares al conjunto de datos de entrenamiento para mejorar el dominio de aplicabilidad del modelo frente a familias de fármacos con alto peso molecular o estructuras complejas.